

DATA MINING ET MACHINE LEARNING

F. CHERIFI

Master 1 GL

2025/2026



INFORMATIONS DU COURS

Coefficient : 2

Crédits : 2

Volume horaire global : 15 semaines

Volume horaire/semaine : 1 séance de cours et 1 séance de TP

Modalité d'évaluation : 60% examen + 40% contrôle continu

Enseignant de la matière : Dr CHERIFI

Contact : feriel.cherifi@univ-bejaia.dz



PLAN DU COURS

Chapitre 1 : Introduction au data Mining et au Machine Learning

Chapitre 2 : Prétraitement des données


Chapitre 3 : Fondements de l'évaluation des modèles

Chapitre 4 : Méthodes d'apprentissage supervisé

Chapitre 5 : Algorithmes de Machine Learning non supervisé

Chapitre 6 : Fouille de Données et Techniques Avancées

Chapitre 7 : Introduction au Deep Learning

The background of the slide is a dark, abstract image featuring a network of white nodes connected by thin lines, resembling a molecular structure or a data network. The nodes are of varying sizes and are distributed across the frame, with a higher concentration in the upper left and right areas.

Chapitre 1

Introduction au machine learning



QU'EST-CE QUE
L'INTELLIGENCE
ARTIFICIELLE ?

DÉFINITION DE L'INTELLIGENCE ARTIFICIELLE (ARTIFICIAL INTELLIGENCE (AI))

L'intelligence artificielle (IA) est un domaine de l'informatique et des mathématiques rassemblant un ensemble de techniques algorithmiques et de théories permettant de réaliser des **machines imitant l'intelligence humaine**. Son but est de reproduire l'intelligence afin d'être capable de résoudre des problèmes complexes.

L'intelligence artificielle est généralement classée comme forte ou faible.

- **L'IA forte** a pour objectif de développer une machine disposant de capacités cognitives proches de l'humain. Cette machine serait capable de trouver seule une solution à un problème qui lui est encore inconnu. Bien que ce soit un sujet de recherche actif, l'IA forte n'existe pas à l'heure actuelle.
- **L'IA faible** consiste à développer des machines permettant de répondre à **un problème précis**. Elle dispose alors de données et d'aide humaine, et doit être capable de simuler le raisonnement humain, sans pour autant comprendre les phénomènes mis en œuvre.

Exemple : traducteur de google, reconnaissance faciale, filtre de spam.

DOMAINE D'APPLICATION DE L'IA





QU'EST-CE QUE
L'APPRENTISSAGE
AUTOMATIQUE ?

QU'EST-CE QUE L'APPRENTISSAGE ?

Pour l'humain, acquisition

- De connaissances (cognition, par ex. une langue)
- D'un savoir-faire (tâche, par ex. marcher)

Pour la machine

C'est le processus de construire un modèle général à partir de données (observations) particulières du monde réel.

Ainsi, le but est double :

- Prédire un comportement face à une nouvelle donnée.
- Approximer une fonction ou une densité de probabilité.

DÉFINITION DE L'APPRENTISSAGE AUTOMATIQUE (MACHINE LEARNING)

Selon *Wikipedia*, la définition de l'apprentissage automatique est :


*« L'apprentissage automatique (en anglais machine learning, littéralement « apprentissage machine ») ou apprentissage statistique est un champ d'étude de l'intelligence artificielle qui **se fonde sur des approches mathématiques et statistiques pour donner aux ordinateurs la capacité d'« apprendre » à partir de données**, c'est-à-dire d'améliorer leurs performances à résoudre des tâches sans être explicitement programmés pour chacune. »*

Par exemple l'apprentissage automatique permet de répondre à des problème tel que :

- Supposons que l'on dispose d'un certain nombre d'images représentant des chiens, et d'autres représentant des chats. Comment classer automatiquement une nouvelle image dans une des catégories « chien » ou « chat » ?

REMARQUE

Le machine learning et intelligence artificielle ne sont pas identiques. L'intelligence artificielle est un terme générique qui désigne différentes stratégies et techniques utilisées pour rendre les machines plus humaines. Le machine learning est l'une des nombreuses branches de l'intelligence artificielle. Si le machine learning relève de l'IA, toutes les activités d'IA ne peuvent pas être appelées machine learning.




QUAND UTILISER LE MACHINE LEARNING ?

Le machine learning peut servir à résoudre des problèmes

- Que l'on ne sait pas résoudre;
- Que l'on sait résoudre, mais dont on ne sait formaliser en termes algorithmiques comment nous les résolvons (c'est le cas par exemple de la reconnaissance d'images ou de la compréhension du langage naturel);
- Que l'on sait résoudre, mais avec des procédures beaucoup trop gourmandes en ressources informatiques (c'est le cas par exemple de la prédiction d'interactions entre molécules de grande taille, pour lesquelles les simulations sont très lourdes);
- Les modèles doivent être personnalisés (médecine personnalisée).

Exemple

Il est très difficile de dire ce qui caractérise un 2.



Exemple

Certaines tâches sont mieux résolues à l'aide d'un algorithme d'apprentissage automatique.

- Reconnaissance des modèles :
 - Identification faciales ou expressions faciales
 - Mots écrits à la main ou prononcés à voix haute
 - Images médicales
- Génération de modèles :
 - Génération d'images ou de séquences animées
- Reconnaissance des anomalies :
 - Transactions inhabituelles par carte de crédit
 - Modèles inhabituels de lectures de capteurs dans une centrale nucléaire
- Prédiction :
 - Cours futurs des actions ou taux de change

Pipeline d'apprentissage automatique (pipeline ML)

1. Collecte de données : La collecte de données est le processus qui consiste à rassembler des données brutes provenant de diverses sources. Ces données peuvent être structurées (comme les bases de données) ou non structurées (comme les textes, les images ou les vidéos). Les données peuvent provenir d'API, du web scraping, de capteurs ou d'une saisie manuelle.

2. Prétraitement des données : Le prétraitement des données consiste à nettoyer et à transformer les données brutes dans un format adapté à l'analyse. Cette étape comprend :

2.1- Nettoyage des données :

- Traitement des valeurs manquantes : les techniques consistent à supprimer les enregistrements comportant des valeurs manquantes, à imputer les valeurs manquantes à l'aide de méthodes statistiques (moyenne, médiane) ou à utiliser des techniques d'imputation avancées telles que K-Nearest Neighbors (KNN).
- Suppression des doublons : identification et suppression des enregistrements en double afin de garantir l'intégrité des données.
- Suppression du bruit : filtrage des valeurs aberrantes ou des points de données non pertinents susceptibles de fausser l'analyse.

Pipeline d'apprentissage automatique (pipeline ML)

2.2- Transformation des données :

- Normalisation/standardisation : mise à l'échelle des caractéristiques numériques dans une plage standard, souvent $[0, 1]$ ou $[-1, 1]$, afin de garantir que toutes les caractéristiques contribuent de manière égale au modèle.
- Codage des variables catégorielles : conversion des données catégorielles en format numérique à l'aide de techniques telles que le codage one-hot, le codage par étiquette ou le codage binaire.

3. Ingénierie des caractéristiques : L'ingénierie des caractéristiques consiste à sélectionner, modifier ou créer de nouvelles caractéristiques à partir des données brutes afin d'améliorer les performances du modèle d'apprentissage automatique. Cette étape nécessite souvent des connaissances spécialisées.

4. Sélection du modèle : La sélection du modèle consiste à choisir l'algorithme d'apprentissage automatique approprié pour entraîner votre modèle à partir de vos données. Le choix dépend du type de problème (classification, régression, clustering), de la taille des données et de leur complexité.

5. Entraînement du modèle : L'entraînement du modèle consiste à alimenter l'algorithme sélectionné avec les données préparées afin d'apprendre les modèles et les relations. Le modèle ajuste ses paramètres afin de minimiser les erreurs et d'améliorer la précision des prédictions.

Pipeline d'apprentissage automatique (pipeline ML)

6. Évaluer le modèle : Évaluer les performances des modèles entraînés sur l'ensemble de validation à l'aide de mesures d'évaluation appropriées (par exemple, exactitude, précision, rappel, F1-score...), puis comparez les performances des différents modèles pour sélectionner celui qui est le plus performant pour le déploiement.

Remarque : Les performances d'un modèle spécifique dépendent de nombreux facteurs, tels que la quantité et la qualité des données d'apprentissage, la complexité et la forme de la relation entre les variables d'entrée et de sortie, ainsi que les contraintes informatiques telles que le temps d'apprentissage disponible et la mémoire. En fonction du problème, **il est souvent nécessaire d'essayer différents modèles et algorithmes afin de trouver ceux qui conviennent le mieux.**

7. Déployer le modèle

- Déployer le modèle dans un environnement de production, sur site ou dans le cloud, à l'aide de plateformes telles qu'AWS, Azure ou Google Cloud Platform.
- Mettre en œuvre des mécanismes de surveillance et de journalisation pour suivre les performances du modèle et détecter toute dérive ou dégradation au fil du temps.

TERMES ET CONCEPTS CLÉS

Le processus automatique de construction d'un modèle est appelé apprentissage ou **entraînement, Training en anglais**.

Données d'entraînement (Training Data) : Aussi appelée données d'apprentissage, c'est un ensemble de données utilisées pour entraîner un modèle.

Données de test (Test Data) : Ensemble de données utilisé pour évaluer la performance d'un modèle après l'entraînement.

Données de validation (Validation Data) : Ensemble de données utilisé pour ajuster les hyperparamètres du modèle, souvent séparé des données de test et d'entraînement.

Modèle (Model) : Un modèle est un algorithme qui apprend à partir des données et fait des prédictions ou des classifications.

Fonction de perte (Loss Function) : Aussi appelée fonction de coût, c'est la différence entre les valeurs de l'étiquette d'entraînement et la prédiction effectuée par le modèle. Les paramètres du modèle sont estimés en minimisant la fonction de perte.


Optimisation : Processus d'ajustement des paramètres du modèle pour minimiser la fonction de perte.

Gradient Descent est l'un des algorithmes d'optimisation les plus courants.


TERMES ET CONCEPTS CLÉS

Overfitting (Sur-apprentissage ou sur-ajustement) : il est caractéristique d'un modèle qui s'**adapte trop précisément** aux données d'entraînement. L'algorithme capture même le bruit ou les variations aléatoires. Au final, si le taux d'erreur sur le training set est bas, la performance est insatisfaisante sur un nouveau jeu de données.


Underfitting (Sous-apprentissage ou sous-ajustement) : Lorsque le modèle n'a pas appris suffisamment des données d'entraînement et donc ne performe pas bien. Cela se produit lorsque le modèle est trop simple ou trop limité pour saisir la complexité des relations présentes dans les données d'entraînement, par exemple, un modèle linéaire utilisé pour modéliser une relation non linéaire. Il produit des prédictions peu fiables. Sa performance est aussi médiocre sur le training set que sur de nouvelles données.



Under-fitting
(too simple to
explain the variance)



Appropriate-fitting



Over-fitting
(forcefitting--too
good to be true)

TERMES ET CONCEPTS CLÉS

Remarque :

Le machine learning repose sur deux piliers fondamentaux :

- d'une part, les données, qui sont les exemples à partir duquel l'algorithme va apprendre;
- d'autre part, l'algorithme d'apprentissage, qui est la procédure que l'on fait tourner sur ces données pour produire un modèle.

Ces deux piliers sont aussi importants l'un que l'autre. D'une part, aucun algorithme d'apprentissage ne pourra créer un bon modèle à partir de données qui ne sont pas pertinentes. D'autre part, un modèle appris avec un algorithme inadapté sur des données pertinentes ne pourra pas être de bonne qualité.

TERMES ET CONCEPTS CLÉS

Hyperparamètres : Paramètres qui contrôlent l'architecture ou le processus d'entraînement d'un modèle. Les valeurs de *hyperparamètres* sont définies avant d'entraîner le modèle

Features (Caractéristiques) : Ce sont les variables ou les attributs utilisés pour entraîner le modèle. Par exemple, dans un modèle de prédiction des prix de l'immobilier, les caractéristiques pourraient inclure la superficie, l'emplacement, et l'âge de la maison.

Étiquettes (Labels) : Ce sont les réponses correctes associées aux données d'entrée dans un problème d'apprentissage supervisé. Par exemple, dans une tâche de classification d'images, les étiquettes pourraient être des catégories comme "chien", "chat", "oiseau", etc.

Normalisation : mise à l'échelle des données dans une plage comprise entre 0 et 1.

Standardisation : mise à l'échelle des données afin d'obtenir une moyenne de 0 et un écart type de 1.

LES ÉLÉMENTS FONDAMENTAUX DU MACHINE LEARNING

On peut regrouper les éléments du machine learning en quatre grandes catégories :

1. Les données (Data) : matière première de l'apprentissage
 - Données d'entraînement : exemples utilisés pour apprendre.
 - Données de test (ou validation) : servent à évaluer la performance.
 - Caractéristiques (features) : attributs ou variables d'entrée.
 - Étiquettes (labels) : résultats à prédire (dans l'apprentissage supervisé).

Exemple : Pour un modèle de reconnaissance d'images de chats :

Données = images

Features = pixels, couleurs, formes

Labels = "chat", "pas chat"

LES ÉLÉMENTS FONDAMENTAUX DU MACHINE LEARNING

2. Le modèle (Model) : structure mathématique qui apprend à partir des données

C'est une fonction paramétrable que le ML va ajuster.

Exemples : régression linéaire, arbre de décision, réseau de neurones...

Le modèle apprend une relation entre les entrées (features) et les sorties (labels).

3. L'algorithme d'apprentissage (Learning Algorithm) : méthode utilisée pour ajuster les paramètres du modèle

Il optimise une fonction de coût / erreur en s'appuyant sur les données.

Exemples : Descente de gradient (gradient descent), Backpropagation (dans les réseaux de neurones), Optimisation bayésienne, Algorithmes spécifiques : ID3, SVM, k-NN, etc.

LES ÉLÉMENTS FONDAMENTAUX DU MACHINE LEARNING

4. La fonction objectif / fonction de perte (Loss Function) : mesure l'erreur entre les prédictions et les vraies valeurs. Le but de l'algorithme est de minimiser cette erreur.

Exemples : Erreur quadratique moyenne (MSE) pour les régressions, Log-loss / cross-entropy pour les classifications, Hinge loss pour les SVM...

Comment ça fonctionne ?

- **Données d'entraînement** : Les données sont fournies à l'algorithme, et le modèle fait une première prédiction (ou classification).
- **Calcul de la fonction coût** : La fonction coût calcule l'écart entre les prédictions du modèle et les vraies valeurs des sorties dans les données d'entraînement. Par exemple, en régression, la fonction coût pourrait être la somme des carrés des erreurs (erreur quadratique moyenne).
- **Optimisation** : L'algorithme utilise des techniques comme la **descente de gradient** pour ajuster les paramètres du modèle de manière à **minimiser** la fonction coût.

Une fois que l'algorithme a trouvé les paramètres qui minimisent la fonction coût, il produit un modèle qui peut être utilisé pour faire des prédictions sur de nouvelles données.

EXEMPLE D'APPLICATION DE L'APPRENTISSAGE AUTOMATIQUE

Prévisions de trafic

Les algorithmes d'apprentissage automatique sont utilisés dans les prévisions de trafic affichées sur nos systèmes de navigation

GPS. Ils mettent en évidence les itinéraires encombrés sur la base d'informations relatives à la localisation et à la vitesse recueillies à partir de nos données quotidiennes.

Réseaux sociaux

Pour les réseaux sociaux, les logiciels d'apprentissage automatique analysent nos données d'utilisation, telles que les personnes

avec lesquelles nous nous sommes connectés, les profils que nous avons visités et nos centres d'intérêt, afin de nous recommander des personnes que nous pourrions connaître.

Filtres anti-spam pour les e-mails

L'apprentissage automatique est appliqué aux filtres anti-spam afin de fournir une solution plus robuste et plus fiable. Il garantit

que le filtre reste à jour pour identifier les derniers stratagèmes utilisés par les spammeurs.

EXEMPLE D'APPLICATION DE L'APPRENTISSAGE AUTOMATIQUE

Magasin sans caisse



EXEMPLE D'APPLICATION DE L'APPRENTISSAGE AUTOMATIQUE

Voiture autonome



AVANTAGES DE L'APPRENTISSAGE AUTOMATIQUE

- **Identifie facilement les tendances et les modèles**

L'apprentissage automatique peut examiner de grands volumes de données et découvrir des tendances et des modèles spécifiques qui ne seraient pas apparents pour les humains.

- **Aucune intervention humaine nécessaire**

L'humain n'a pas besoin de surveiller le projet à chaque étape. Les machines ont la capacité d'apprendre, cela leur permet de faire des prédictions et d'améliorer les algorithmes par eux-mêmes. Les logiciels antivirus en sont un exemple courant : ils apprennent à filtrer les nouvelles menaces à mesure qu'elles sont reconnues.

- **Amélioration continue**

Au fur et à mesure que les algorithmes acquièrent de l'expérience, ils continuent à améliorer leur précision et leur efficacité. Cela leur permet de prendre de meilleures décisions.

- **Traitement des données multidimensionnelles**

Les algorithmes d'apprentissage automatique sont capables de traiter des données multidimensionnelles et ce dans des environnements dynamiques, volumineux et complexes.

- **Applications étendues**

L'apprentissage automatique s'applique dans tous les domaines et permet d'offrir une expérience beaucoup plus personnelle aux clients tout en ciblant les bons clients.

FAIBLESSES DE L'APPRENTISSAGE AUTOMATIQUE

- **Acquisition de données**

L'apprentissage automatique nécessite des ensembles de données massifs pour s'entraîner, et ceux-ci doivent être de bonne qualité et objectif.

- **Temps et ressources**

L'apprentissage automatique a besoin de suffisamment de temps pour permettre aux algorithmes d'apprendre et de se développer suffisamment pour remplir leur mission avec un degré considérable de précision et de pertinence. Il a également besoin de ressources massives pour fonctionner. Cela peut un investissement initial important pour le matériel.


- **Interprétation des résultats**

Un autre défi majeur est la capacité d'interpréter avec précision les résultats générés par les algorithmes. Il faudrait également choisir soigneusement les algorithmes en fonction de votre objectif.

- **Haute susceptibilité aux erreurs**

L'apprentissage automatique est autonome mais très sensible aux erreurs. Si l'algorithme est entraîné avec des ensembles de données suffisamment petits pour ne pas être inclusifs alors les prédictions seront biaisées. Cela peut déclencher une chaîne d'erreurs qui peuvent passer inaperçues pendant de longues périodes. Et lorsqu'elles sont remarquées, il faut un certain temps pour reconnaître la source du problème, et encore plus pour le corriger.

LES TYPES D'APPRENTISSAGE AUTOMATIQUE



APPRENTISSAGE SUPERVISÉ

L'apprentissage supervisé (supervised learning) s'intéresse aux données étiquetées. L'objectif est de prédire l'étiquette (inconnue) y associée à une nouvelle observation x , à partir de la connaissance fournie par les N observations étiquetées du jeu de données $(x_n, y_n) \ 1 \leq n \leq N$.

Modèle traditionnel



Apprentissage supervisé



APPRENTISSAGE SUPERVISÉ

Régression

La régression est une technique d'apprentissage supervisé permettant de prédire des quantités numériques. Un exemple de tâche de régression consiste à prédire le coût d'une maison dans un ensemble de données immobilières.

Remarque :

Certains algorithmes d'apprentissage automatique (tels que les SVM, les forêts aléatoires et les kNN) prennent en charge la régression ainsi que la classification.



Classification

La classification est également une technique d'apprentissage supervisé, elle sert à prédire des quantités catégoriques. Un exemple de tâche de classification est l'occurrence de spam ou de fraude

Les algorithmes de classification en apprentissage machine comprennent les algorithmes suivants :

- Arbres de décision (un seul arbre)
- Forêts aléatoires (plusieurs arbres)
- k Nearest Neighbor (kNN)
- Régression logistique
- Naïve Bayes
- Support Vector Machines (SVM)

Il existe de nombreux problèmes d'apprentissage automatique dont l'objectif est de classer les entrées dans l'une des deux catégories. Souvent, une catégorie représente des points de données ayant une propriété particulière et l'autre catégorie joue le rôle d'une classe « d'arrière-plan » qui inclut tout le reste. Habituellement, la classe représentant la catégorie d'intérêt est appelée classe « positive » et la classe d'arrière-plan est appelée classe « négative ».



APPRENTISSAGE SEMI-SUPERVISÉ

Il combine l'apprentissage supervisé et non supervisé, en utilisant à la fois des données étiquetées et non étiquetées pour entraîner des modèles sur des tâches de classification et de régression. Les méthodes d'apprentissage semi-supervisées sont particulièrement utiles dans les situations où il est difficile ou coûteux d'obtenir un volume suffisant de données étiquetées, mais où les données non étiquetées sont relativement faciles à acquérir en revanche. Dans de tels cas, ni les méthodes d'apprentissage entièrement supervisées ni non supervisées ne fourniront des solutions adéquates.

APPRENTISSAGE PAR TRANSFERT

L'**apprentissage par transfert** (ou **transfer learning**) est une technique puissante qui permet de réutiliser un modèle préalablement entraîné sur une tâche spécifique et de l'adapter à une nouvelle tâche, souvent avec un jeu de données plus petit ou plus limité. Cette approche est particulièrement utile dans des domaines où il est difficile ou coûteux de collecter une grande quantité de données étiquetées.

Exemple : Plutôt que de créer un modèle de zéro, une entreprise, qui veut créer un système de réponse automatique pour le service client, peut utiliser un modèle pré-existant qui a été pré-entraîné sur une grande quantité de texte. Ensuite, elle effectue un **fine-tuning** sur son propre jeu de données de questions-réponses spécifiques au service client pour affiner le modèle et le rendre efficace pour cette tâche.

APPRENTISSAGE NON-SUPERVISÉ

Dans le cas de l'apprentissage non supervisé, l'apprentissage par la machine se fait de façon totalement autonome. Des données sont communiquées à la machine sans lui fournir les exemples de résultats attendus en sortie. Elle propose ainsi des réponses à partir d'analyses et de groupement de données.

- **Clustering**

Le clustering est une technique d'apprentissage non supervisée permettant de regrouper des données similaires.

Les algorithmes de clustering placent les points de données dans différents clusters sans connaître la nature des points de données.

Les algorithmes de clustering en apprentissage machine comprennent les algorithmes suivants :

- k-Means
- Hierarchical Cluster Analysis (HCA)
- Expectation Maximization

- **Réduction de la dimensionnalité**

Parmi les algorithmes d'apprentissage non supervisé qui impliquent une réduction de la dimensionnalité :

- Principal Component Analysis (PCA)
- Kernel PCA
- Locally Linear Embedding (LLE)
- t-distributed Stochastic Neighbor Embedding (t-SNE)

APPRENTISSAGE PAR RENFORCEMENT

L'apprentissage par renforcement, également un sous-ensemble de l'apprentissage automatique, implique des essais et des erreurs afin de maximiser la récompense d'un agent. L'apprentissage par renforcement profond combine les forces de l'apprentissage profond et de l'apprentissage par renforcement. En particulier, l'agent de l'apprentissage par renforcement est remplacé par un réseau neuronal.

