




Chapitre 3

Fondements de l'évaluation des modèles

Evaluation des modèles d'apprentissage automatique

L'évaluation des modèles d'apprentissage automatique vise à mesurer leur capacité à produire des prédictions fiables et pertinentes sur des données nouvelles, en s'assurant qu'ils apprennent des relations générales plutôt que de mémoriser les données d'entraînement. Elle repose sur un ensemble de méthodes et de métriques permettant de tester la capacité de généralisation du modèle et de détecter des problèmes majeurs tels que le surapprentissage et le sous-apprentissage.

Le choix des métriques est crucial et dépend du type de problème traité : en classification, l'objectif est d'attribuer correctement une classe à chaque observation, tandis qu'en régression il s'agit de prédire une valeur numérique continue. Chaque tâche nécessite donc des métriques spécifiques, car une mesure adaptée à la classification peut être inappropriée pour la régression.

Enfin, l'évaluation permet également de tester la robustesse du modèle et de l'ajuster en fonction des données et du contexte afin de garantir une utilisation efficace dans des situations réelles.

Méthodes de validation

Pour évaluer un modèle de machine learning, plusieurs méthodes de validation sont couramment utilisées, selon la taille des données et le type du problème :

1. **Validation simple (Hold-out)** : cette méthode consiste à diviser le jeu de données initial en deux ou trois sous-ensembles distincts, généralement un jeu d'entraînement et un jeu de test, parfois complétés par un jeu de validation. Le modèle est entraîné sur le jeu d'entraînement puis évalué sur le jeu de test. Cette approche est facile à mettre en œuvre et peu coûteuse en calcul, mais elle présente l'inconvénient de **dépendre fortement du découpage des données**. Une mauvaise partition peut conduire à une estimation biaisée des performances, en particulier lorsque le jeu de données est de petite taille.

2. **Validation croisée (cross-validation)** : ces méthodes reposent sur des découpages répétés des données afin d'obtenir une estimation plus robuste des performances du modèle. Elles permettent de réduire le biais lié à un seul découpage des données, mais peuvent être coûteuses en calcul. Il existe plusieurs variantes de la validation croisée :

- Validation croisée k-fold
- Validation croisée stratifiée (variante de la k-fold, surtout utilisée en classification)
- Leave-One-Out Cross-Validation (LOOCV) (cas particulier de la k-fold)
- Repeated k-fold (k-fold répétée plusieurs fois avec des découpages différents)

3. **Méthodes de validation pour séries temporelles** : ces méthodes respectent l'ordre chronologique des données afin d'éviter toute fuite d'information.

- Validation par fenêtre glissante (sliding window)
- Validation par fenêtre croissante (expanding window)

Elles sont essentielles pour les données dépendantes du temps.

Importance de la séparation des données

La séparation stricte des données en ensembles **distincts** est une condition fondamentale pour une évaluation correcte des modèles de machine learning. Elle permet d'éviter que le modèle ne soit évalué sur des données qu'il a déjà vues, ce qui conduirait à une surestimation de ses performances. Une bonne séparation garantit ainsi une mesure plus réaliste et plus fidèle des capacités du modèle en conditions réelles.

- Problème de la fuite de données (Data leakage)


La fuite de données se produit lorsque des informations issues du jeu de validation ou de test sont utilisées, directement ou indirectement, lors de l'entraînement du modèle. Ce phénomène peut provenir de mauvaises pratiques, telles qu'un prétraitement réalisé avant la séparation des données ou l'utilisation de variables contenant des informations futures. La fuite de données fausse l'évaluation en donnant une impression artificiellement élevée des performances du modèle et doit être rigoureusement évitée.

Validation croisée k-fold

- ❖ Le principe de la validation croisée k -fold est de diviser le jeu de données en k sous-ensembles de taille approximativement égale, appelés *folds*. Le modèle est ensuite entraîné k fois. À chaque itération, $k-1$ folds sont utilisés pour l'apprentissage et le fold restant sert à l'évaluation.
- ❖ Ce processus est répété jusqu'à ce que chaque fold ait été utilisé une fois comme ensemble de test. Les performances finales du modèle sont obtenues en faisant la **moyenne des résultats** sur les k itérations.
- ❖ Le k -fold cross-validation permet de réduire la dépendance à un seul découpage des données, de mieux détecter le surapprentissage et de fournir une estimation plus stable et plus représentative des performances réelles du modèle.
- ❖ 10-fold cross validation est courante, mais des valeurs plus faibles de k sont souvent utilisées lorsque l'apprentissage prend beaucoup de temps.

Validation croisée k-fold

1. Diviser les données en k sous-échantillons



2. Laisser itérativement un sous-échantillon de côté pour le jeu de test, entraîner sur le reste

itération	s'entraîner sur	tester sur
1	S2,S3,S4,S5,S6,S7	S1
2	S1,S3,S4,S5,S6,S7	S2
3	S1,S2,S4,S5,S6,S7	S3
4	S1,S2,S3,S5,S6,S7	S4
5	S1,S2,S3,S4,S6,S7	S5
6	S1,S2,S3,S4,S5,S7	S6
7	S1,S2,S3,S4,S5,S6	S7

Biais, variance et compromis biais–variance

La compréhension du biais, de la variance et de leur compromis est essentielle pour interpréter correctement les résultats d'évaluation et améliorer les modèles de machine learning.

❖ Définition du biais

Le biais correspond à l'erreur introduite par des hypothèses trop simplificatrices faites par le modèle pour apprendre les données. Un modèle à fort biais ne parvient pas à capturer la complexité réelle des relations entre les variables, ce qui conduit à des performances insuffisantes aussi bien sur les données d'entraînement que sur les données de test. Ce phénomène est généralement associé au sous-apprentissage, où le modèle est trop simple pour représenter correctement le problème étudié.

❖ Définition de la variance

La variance mesure la sensibilité du modèle aux variations des données d'entraînement. Un modèle à forte variance s'adapte excessivement aux particularités du jeu d'entraînement, y compris au bruit, ce qui entraîne de bonnes performances sur ces données mais de mauvaises performances sur des données nouvelles. Ce comportement est caractéristique du surapprentissage et se rencontre souvent avec des modèles trop complexes.

❖ Le compromis biais–variance

Le biais et la variance influencent directement la capacité de généralisation d'un modèle de machine learning. Un biais élevé empêche le modèle d'apprendre correctement les structures sous-jacentes des données, tandis qu'une variance élevée rend ses prédictions sensibles aux variations des données d'entraînement et instables face à de nouvelles observations. L'analyse des performances sur différents jeux de données permet d'identifier si les erreurs proviennent principalement du biais ou de la variance. Le compromis biais–variance décrit l'équilibre nécessaire entre la simplicité et la complexité du modèle : réduire le biais en augmentant la complexité tend à accroître la variance, et inversement. L'objectif est donc de trouver un niveau de complexité optimal qui minimise l'erreur de généralisation, ce qui constitue un enjeu central dans le choix du modèle et le réglage des hyperparamètres.

Métriques pour la classification

Les métriques pour la classification permettent d'évaluer la performance d'un modèle chargé d'attribuer une classe à chaque observation. Elles mesurent dans quelle mesure les prédictions du modèle correspondent aux classes réelles.

Pour les tâches de classification, les résultats peuvent être résumés dans une matrice appelée **matrice de confusion**.

		Étiquette authentique	
		Positive	Négative
Étiquette prédite	Positive	TP	FP
	Négative	FN	TN

Matrice de confusion

Métriques pour la classification

Pour la classification binaire, la matrice de confusion répartit les échantillons de test en quatre catégories, en fonction de leurs étiquettes réelles et prédites :

- Vrais positifs (TP) : échantillons pour lesquels les étiquettes réelles et prédites sont toutes deux positives. Exemple : le patient a un cancer (+) et le modèle classe cet échantillon comme cancer (+).
- Vrais négatifs (TN) : échantillons pour lesquels les étiquettes réelles et prédites sont toutes deux négatives. Exemple : le patient n'a pas de cancer (-) et le modèle classe cet échantillon comme non cancéreux (-).
- Faux positifs (FP) : échantillons pour lesquels l'étiquette réelle est négative et l'étiquette prédite est positive. Exemple : le patient n'a pas de cancer (-) et le modèle classe cet échantillon comme cancer (+).
- Faux négatifs (FN) : échantillons pour lesquels l'étiquette réelle est positive et l'étiquette prédite est négative. Exemple : le patient a un cancer (+) et le modèle classe cet échantillon comme non cancéreux (-).

Métriques pour la classification

Plusieurs métriques de performance peuvent être dérivées de la matrice de confusion. On distingue les métriques de base, qui se concentrent uniquement sur les faux positifs ou les faux négatifs, et les métriques de synthèse, qui visent à fournir une vue d'ensemble des performances à l'aide d'une seule mesure.

Sensitivity (également appelée recall): fraction des échantillons positifs effectivement classés comme positifs.

$$\text{Sensitivity} = \frac{TP}{TP+FN}$$

Specificity: fraction des échantillons négatifs effectivement classés comme négatifs.

$$\text{Specificity} = \frac{TN}{TN+FP}$$

Métriques pour la classification

Precision : fraction des échantillons classés positifs qui sont effectivement positifs.

$$\text{Precision} = \frac{TP}{TP+FP}$$

Accuracy : fraction des échantillons correctement classés.

$$\text{Accuracy} = \frac{TP+TN}{TP+FP+TN+FN}$$

Balanced accuracy: mesure de précision qui tient compte des échantillons déséquilibrés.

$$\text{Balanced accuracy} = \frac{\text{Sensitivity} + \text{Specificity}}{2}$$

F1-score : moyenne harmonique de précision et de sensibilité (rappel).

$$\text{F1-score} = \frac{2TP}{2TP+FP+FN}$$


Métriques pour la classification

Area under the receiver operating characteristic curve (ROC AUC)

- ❖ De nombreux algorithmes de classification produisent une valeur continue qui est ensuite soumise à un seuil afin d'obtenir une étiquette binaire. Dans ce cas, il peut être intéressant d'étudier les performances pour différents seuils sur le résultat. Les deux principaux outils utilisés à cette fin sont la courbe ROC (receiver operating characteristic) et la courbe PR (precision recall). La courbe ROC représente la sensibilité en fonction de la spécificité. Elle peut être résumée par une seule valeur : l'aire sous la courbe ROC (ROC AUC).
- ❖ Une classification parfaite correspond à une AUC ROC de 1 et une classification aléatoire à une AUC ROC de 0,5. La courbe ROC devient moins intéressante pour les classes fortement déséquilibrées.

Métriques pour la classification binaire

Area under the receiver operating characteristic curve (ROC AUC)



courbe ROC en orange et AUC en gris

Métriques pour la régression

Dans les paramètres de régression, le résultat à prédire y est continu, par exemple l'âge d'un individu, ses scores cognitifs ou son taux de glucose. Les mesures d'erreur correspondantes évaluent l'écart entre la prédiction $\hat{y}$ et la valeur observée y . Plusieurs métriques sont utilisées pour mesurer cet écart :

- Erreur Absolue Moyenne (MAE – Mean Absolute Error)
- Erreur Quadratique Moyenne (MSE – Mean Squared Error)
- Racine de l'Erreur Quadratique Moyenne (RMSE – Root Mean Squared Error)
- Coefficient de détermination (R^2)

Métriques pour la régression

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}|$$

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2$$

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2}$$

$$R^2 = 1 - \frac{\sum (y_i - \hat{y})^2}{\sum (y_i - \bar{y})^2}$$

Where,

$\hat{y}$ – predicted value of y

$\bar{y}$ – mean value of y

Choix des métriques

Le choix des métriques est une étape stratégique dans l'évaluation des modèles de machine learning. Une sélection judicieuse, tenant compte du déséquilibre des données, des objectifs métier et du coût des erreurs, permet d'obtenir une évaluation plus pertinente et d'orienter efficacement le développement et l'amélioration des modèles.

1. Adaptation des métriques au déséquilibre des classes

Lorsque les classes sont déséquilibrées, certaines métriques couramment utilisées, comme l'accuracy, peuvent donner une vision trompeuse de la performance du modèle. En effet, un modèle qui prédit systématiquement la classe majoritaire peut obtenir une accuracy élevée sans être réellement performant. Dans ce contexte, des métriques telles que la précision, le rappel, le F1-score ou l'AUC sont plus appropriées, car elles permettent d'évaluer plus finement la capacité du modèle à identifier correctement les classes minoritaires.

2. Alignement des métriques avec les objectifs

Le choix des métriques doit être étroitement lié aux objectifs métier ou applicatifs du modèle. Selon le domaine, certaines erreurs peuvent être plus coûteuses que d'autres. Par exemple, dans des applications sensibles, il peut être préférable de maximiser le rappel afin de réduire le risque de manquer des cas importants. Une métrique pertinente est donc celle qui reflète au mieux les priorités et les contraintes réelles de l'application.

3. Prise en compte du coût des erreurs

Toutes les erreurs de prédiction n'ont pas le même impact. Les faux positifs et les faux négatifs peuvent entraîner des conséquences très différentes selon le contexte. Le choix des métriques doit intégrer cette asymétrie en mettant l'accent sur celles qui pénalisent le plus fortement les erreurs les plus critiques. Cette approche permet d'évaluer les modèles de manière plus réaliste et plus adaptée aux enjeux concrets.

Fin