


The background of the slide is a dark, abstract image featuring a network of white nodes connected by thin lines, resembling a molecular structure or a data network. The nodes are of varying sizes and are distributed across the frame, with a higher concentration in the upper left and right areas.

Chapitre 5

Algorithmes de Machine Learning non supervisé

Clustering


En machine learning, la technique de l'apprentissage non supervisé (unsupervised learning) consiste à entraîner des modèles, sans réaliser d'étiquetage manuel ou automatique des données au préalable. Les algorithmes regroupent les données en fonction de leur similitude, sans aucune intervention humaine.

Le **clustering** est la technique la plus populaire en apprentissage non supervisé, dans laquelle les données sont regroupées en fonction de la similarité entre les points de données. Cela consiste à regrouper les individus en classes avec une grande homogénéité intra-classe et une forte hétérogénéité inter-classe.

Clustering

Il existe deux types de méthodes de clustering :

1. Méthode hiérarchique.
2. Méthode non hiérarchique.



Clustering Hiérarchique vs Clustering non-Hiérarchique

Clustering Hiérarchique	Clustering non-Hiérarchique
Ne nécessite pas un nombre prédéfini de cluster	Le nombre de clusters doit être défini avant l'exécution
Peu adapté pour les grands ensembles de données	Efficace et évolutif pour les grands ensembles de données
Plus facile à interpréter grâce aux dendrogrammes	On suppose que les clusters sont sphériques et de taille égale

Clustering K-means

- ❖ L'algorithme **K-moyennes** (**k-means** en anglais) regroupe les données en cherchant à répartir les échantillons en (n) groupes de variance égale. Cet algorithme **nécessite de spécifier à l'avance le nombre de clusters**. Il est bien adapté aux grands volumes de données et a été utilisé dans un large éventail de domaines et d'applications.
- ❖ L'algorithme des k-moyennes divise un ensemble d'échantillons en K groupes (clusters) disjoints, chacun étant décrit par la moyenne μ des échantillons du groupe. Ces moyennes sont communément appelées les « **centroïdes** » des groupes.

Clustering K-means

❖ Pseudo code : Algorithme K-means

Entrée :

- K : le nombre de cluster à former
- Le training Set (matrice de données)

DEBUT

Choisir aléatoirement K points. Ces points sont les centres des clusters (nommé centroid).

REPETER

- Affecter chaque point au groupe dont il est le plus proche à son centre
- Recalculer le centre de chaque cluster et modifier le centroïde

JUSQU'À CONVERGENCE OU (stabilisation de l'inertie totale de la population)

FIN ALGORITHME

Note : la convergence de l'algorithme K-Means peut être l'une des conditions suivantes :

- Un nombre d'itérations fixé à l'avance, dans ce cas, K-means effectuera les itérations et s'arrêtera peu importe la forme de clusters composés.
- Stabilisation des centres de clusters (les centroids ne changent plus lors des itérations).


Clustering Hiérarchique

- ❖ Le **regroupement hiérarchique** est un algorithme d'apprentissage non supervisé utilisé pour regrouper des points de données similaires en clusters. Il construit une hiérarchie de clusters à plusieurs niveaux, soit en fusionnant des clusters plus petits en clusters plus grands (**agglomération**), soit en divisant un grand cluster en clusters plus petits (**division**). Il en résulte une structure arborescente appelée **dendrogramme**.
- ❖ Un dendrogramme est une **représentation visuelle** qui illustre la disposition des clusters et leurs relations mutuelles. La hauteur des branches d'un dendrogramme reflète la distance ou la dissimilarité à laquelle les groupes sont fusionnés. Les hauteurs inférieures indiquent que les clusters sont reliés à de plus petites distances, ce qui représente une plus grande similarité.

Clustering Hiérarchique

❖ Types de regroupement hiérarchique

Dans la technique du regroupement hiérarchique, vous trouverez plusieurs types de regroupements, chacun apportant des informations et des résultats différents. Les deux principaux types de regroupements hiérarchique sont l'agglomération (de bas en haut) et la division (de haut en bas).



Clustering Hiérarchique

1. Agglomération (de bas en haut)

Le regroupement agglomératif commence par considérer chaque point de données comme un cluster individuel. Ensuite, il fusionne itérativement les paires de clusters les plus proches jusqu'à ce qu'il ne reste qu'un seul cluster, ou jusqu'à ce qu'une condition d'arrêt soit atteinte, comme un nombre prédéfini de clusters.

Cette méthode est dite **ascendante**, car elle commence par les points de données individuels (le bas) et progresse vers un cluster final (le sommet).

Déroulement du regroupement agglomératif :

1. Traitez chaque point de données comme un cluster unique.
2. Calculez la distance entre chaque paire de clusters.
3. Fusionnez les deux clusters dont la distance est la plus faible.
4. Mettez à jour la matrice de distance pour refléter le nouvel ensemble de clusters.
5. Répétez les étapes 2 à 4 jusqu'à ce que tous les points soient regroupés en un seul cluster.

Cette méthode est largement utilisée grâce à sa simplicité et à sa facilité de mise en œuvre.

Clustering Hiérarchique

2. Diviser (du haut vers le bas)

Le regroupement divisé commence avec tous les points de données regroupés dans un seul cluster, puis les divise récursivement en groupes de plus en plus petits. Ce processus se poursuit jusqu'à ce que chaque point de données soit isolé dans son propre cluster.

Cette méthode est également connue sous le nom d'approche **descendante**, car elle commence avec un seul cluster (le sommet) et le décompose progressivement en clusters plus petits.

Déroulement du regroupement divisé :

1. Commencez avec un grand cluster contenant tous les points de données.
2. Divisez le cluster en deux groupes aussi différents que possible.
3. Appliquez récursivement le processus de division à chaque groupe résultant.

Les méthodes de division sont généralement plus coûteuses en termes de calcul en raison de leur nature récursive. De plus, la précision de cette approche dépend fortement de la stratégie de division choisie. Les méthodes agglomératives, en revanche, sont plus courantes en raison de leur simplicité de mise en œuvre.

Note : Le clustering hiérarchique divisé n'est pas aussi facilement pris en charge dans les bibliothèques Python standard que le clustering agglomératif. Une approche consiste à utiliser des algorithmes de regroupement tels que les k-moyennes de manière récursive.

Clustering Hiérarchique

❖ Critères de liaison

Les critères de liaison jouent un rôle essentiel dans les méthodes de regroupement hiérarchique, car ils déterminent la manière dont les distances entre les clusters sont calculées tout au long du processus de fusion. En d'autres termes, ils influencent la façon dont les clusters sont unis et décident de l'ordre dans lequel ils sont regroupés.

Les critères de liaison sont utilisés pour évaluer la proximité entre deux clusters à chaque étape de l'**agglomération**, en fonction des distances entre les éléments qui les composent. Il existe plusieurs approches pour calculer cette distance, chacune ayant des implications différentes sur la structure finale des clusters.

Clustering Hiérarchique

❖ Critères de liaison

Les critères de liaison les plus couramment utilisés sont :

Liaison simple (plus proche voisin) : Ce critère mesure la distance entre les **deux points les plus proches**, chacun appartenant à des clusters différents. Ce type de liaison tend à créer des clusters qui sont relativement denses.

Liaison complète (plus éloigné voisin) : La distance entre les deux clusters est déterminée par la distance entre les **points les plus éloignés** de chaque cluster. Ce critère a tendance à créer des clusters plus équilibrés, car il évite la fusion de clusters trop disjoints. Cependant, il peut être plus sensible aux outliers.

Liaison moyenne (moyenne) : Dans ce cas, la distance entre deux clusters est calculée comme **la moyenne des distances entre tous les points de chaque cluster**. Cela permet de trouver un compromis entre les critères de liaison simple et complète, en prenant en compte l'ensemble des distances sans privilégier les points les plus proches ni les plus éloignés.

Liaison centroidale : Ce critère considère la **distance entre les centroïdes des deux clusters**. Le centroïde est un point représentatif de la moyenne de toutes les positions des éléments dans un cluster.

Density-based spatial clustering of applications with noise (DBSCAN)

Le **DBSCAN** est un algorithme non supervisé très connu en matière de Clustering. Il a été proposé en 1996 par Martin Ester, Hans-Peter Kriegel, Jörg Sander et Xiawei Xu.

Les champs d'application sont divers : analyse cartographique, analyse de donnée, segmentation d'image....

L'algorithme DBSCAN nécessite essentiellement deux paramètres, qui sont renseignés librement par l'utilisateur :

- **eps (ϵ)** : spécifie la distance maximale à laquelle les points doivent être proches les uns des autres pour être considérés comme faisant partie d'un même cluster. Cela signifie que si la distance entre deux points est inférieure ou égale à cette valeur (ϵ), ces points sont considérés comme des voisins.
- **minPts** : le nombre minimum de points nécessaires pour former une région dense. Par exemple, si nous définissons le paramètre *minPts* à 5, alors il faut au moins 5 points pour former une région dense.


Density-based spatial clustering of applications with noise (DBSCAN)

Le DBSCAN est un algorithme qui définit des clusters en utilisant l'**estimation de la densité locale**. On peut le diviser en 4 étapes :

1. Pour chaque observation, l'algorithme compte combien d'observations se trouvent à une distance ϵ de celle-ci. Cette région est appelée le voisinage ϵ de l'observation.
2. Si une observation a au moins *minPts* observations dans son voisinage ϵ (y compris elle-même), alors elle est considérée comme une **observation centrale (core instance)**. En d'autres termes, les observations centrales sont celles qui se trouvent dans des régions denses.
3. Toutes les observations situées dans le voisinage d'une observation centrale appartiennent au même cluster. Ce voisinage peut inclure d'autres observations centrales ; ainsi, une longue séquence d'observations centrales voisines forme un seul cluster.
4. Toute observation qui n'est pas une observation centrale et qui n'a pas d'observation centrale dans son voisinage est considérée comme une anomalie.

Density-based spatial clustering of applications with noise (DBSCAN)

MinPts = 5



Fin