

Chapitre 2

Prétraitement des données

Introduction

Lorsqu'on démarre un nouveau projet lié au machine learning, les données acquises sont rarement parfaites dès le départ. Il est donc essentiel de procéder au nettoyage des données au début de chaque nouveau projet. Cette étape peut sembler facultative pour de nombreux débutants, cependant elle est cruciale ! Sans un prétraitement adéquat des données, le modèle peut aboutir à des résultats erronés.

Qu'est-ce que le prétraitement des données ?

Le prétraitement des données est un aspect essentiel de la préparation des données. Il s'agit de tout traitement appliqué aux données brutes afin de les préparer à des tâches d'analyse ou de traitement ultérieures.

Le prétraitement des données pour l'apprentissage machine (ML) fait référence à la préparation et à la transformation des données brutes dans un format adapté à l'entraînement des modèles ML. Il s'agit d'une étape essentielle dans un pipeline ML (ou AI), car elle a un **impact direct sur les performances et la précision des modèles**.

Le prétraitement des données implique plusieurs techniques telles que le nettoyage des données pour gérer les valeurs manquantes, la suppression des valeurs aberrantes, la mise à l'échelle, le codage des variables catégorielles et la division des données en ensembles d'entraînement et de test. Ces techniques sont essentielles pour garantir que les données sont dans un format cohérent et utilisable pour les algorithmes d'ML.

Qu'est-ce que le prétraitement des données ?

Remarques :

1- Bien que souvent utilisés de manière interchangeable, le **nettoyage** des données et le **prétraitement** des données ne sont pas identiques : le nettoyage des données est un sous-ensemble du prétraitement, principalement concerné par l'identification et la correction des erreurs et des incohérences dans l'ensemble de données. Le prétraitement des données, en revanche, est un terme générique qui inclut le nettoyage des données et d'autres processus tels que la normalisation, la transformation et l'extraction de caractéristiques, qui sont essentiels pour préparer les données à l'analyse.

2- La **préparation** des données et le **prétraitement** des données sont souvent utilisés comme synonymes, mais ils peuvent avoir des connotations différentes. Préparation des données Il peut s'agir d'une catégorie plus large, comprenant le prétraitement, la collecte de données et l'intégration. Elle englobe l'ensemble du processus de préparation des données à l'analyse, depuis leur collecte jusqu'à leur intégration dans les outils d'analyse. Le prétraitement des données, tout en faisant partie de la préparation, est spécifiquement axée sur la transformation et le conditionnement des données avant l'analyse.

| Pourquoi le prétraitement des données est-il important ?

Éliminer les erreurs : le nettoyage s'agit d'une technique essentielle de prétraitement des données. Elle permet d'éliminer les erreurs, d'imputer les valeurs manquantes et de corriger les incohérences. Par exemple, un jeu de données client comportant des entrées redondantes en raison d'erreurs techniques serait nettoyé afin de garantir que chaque enregistrement client est unique et représenté avec précision.

Rendre les données uniformes : grâce à la normalisation qui revient à établir des conditions de concurrence équitables, où des mesures disparates sont ajustées à une échelle uniforme, permettant des comparaisons équitables.

Garantir des données de haute qualité : le prétraitement des données influence directement la précision de l'analyse. Les données prétraitées, dépourvues de bruit non pertinent et d'incohérences, permettent aux modèles de discerner et d'apprendre des caractéristiques importantes, améliorant ainsi la précision.

| Pourquoi le prétraitement des données est-il important ?

Affiner la précision et les performances du modèle

Le prétraitement des données dans le machine learning nous permet de supprimer de nombreux obstacles qui peuvent nuire aux performances du modèle. Cela nous aide à faire des prévisions plus précises, plus fiables et plus robustes. Le prétraitement protège contre le surapprentissage, où un modèle pourrait autrement internaliser le bruit dans le cadre du signal, compromettant sa capacité à se généraliser à de nouvelles données. Des techniques telles que la normalisation et la mise à l'échelle des fonctionnalités favorisent l'adaptabilité d'un modèle.

Étapes du prétraitement des données

Le prétraitement des données comporte plusieurs étapes, chacune répondant à des défis spécifiques liés à la qualité, à la structure et à la pertinence des données. Ces étapes clés, se déroulent généralement dans l'ordre suivant :

- Étape 1 : Comprendre les données : Avant de vous lancer dans le prétraitement, il est important de bien comprendre l'ensemble de données. Effectuez une analyse exploratoire des données afin d'identifier la structure des données en question. Ce que vous voulez comprendre en particulier, c'est ce qui suit :
- Caractéristiques principales
- Anomalies potentielles
- Les relations

Si vous ne comprenez pas d'abord les caractéristiques de l'ensemble de données, il est fort probable que vous appliquiez des méthodes de prétraitement incorrectes, ce qui faussera les données.

Étapes du prétraitement des données

- Étape 2 : Nettoyage des données : Le nettoyage des données consiste à identifier et à corriger les erreurs ou les incohérences dans les données afin de s'assurer qu'elles sont exactes et complètes afin de s'assurer que les données sont de haute qualité et adaptées à l'analyse ou à l'apprentissage des modèles. Le nettoyage des données comprend généralement :

Traitement des valeurs manquantes : Utiliser des stratégies telles que l'imputation moyenne/mode, la suppression ou les modèles prédictifs pour compléter ou supprimer les données manquantes.

Suppression des doublons : Élimination des enregistrements en double afin de garantir que chaque entrée est unique et pertinente. Les entrées de données en double peuvent surreprésenter une entrée dans votre analyse, ce qui peut conduire à une conclusion erronée.

Correction des formats incohérents : Normaliser les formats (par exemple, les formats de date, les chaînes de caractères) pour maintenir la cohérence.

Étapes du prétraitement des données

- Étape 3 : Intégration des données

L'intégration des données consiste à combiner des données provenant de sources multiples pour créer un ensemble de données unifié. Cela est souvent nécessaire lorsque les données sont collectées à partir de différents systèmes sources. Parmi les techniques utilisées pour l'intégration des données, on peut citer

Correspondance des schémas : Alignement des champs et des structures de données provenant de différentes sources afin d'en assurer la cohérence.

Déduplication des données : Identification et suppression des doublons dans plusieurs ensembles de données.

- Étape 4 : Transformation des données

La transformation des données permet de convertir les données dans des formats adaptés à l'apprentissage automatique. Par exemple :

Mise à l'échelle et normalisation : L'ajustement des valeurs numériques à une échelle commune est souvent nécessaire pour les algorithmes qui s'appuient sur des mesures de distance.

Encodage de variables catégorielles : Conversion de données catégorielles en valeurs numériques à l'aide de techniques d'encodage.

Ingénierie et extraction de caractéristiques : Créer de nouvelles fonctionnalités ou sélectionner des fonctionnalités importantes pour améliorer les performances du modèle.

Étapes du prétraitement des données

- Étape 5 : Réduction des données

La réduction des données permet de simplifier l'ensemble des données en réduisant le nombre de caractéristiques ou d'enregistrements tout en préservant les informations essentielles. Cela permet d'accélérer l'analyse et la formation des modèles sans sacrifier la précision. Cette méthode peut améliorer les performances du modèle et réduire la complexité des calculs. Les techniques de réduction des données comprennent :

Sélection des caractéristiques : Choisir les caractéristiques les plus importantes contribuant à la performance de l'analyse ou du modèle.

Analyse en composantes principales (PCA) : Une technique de réduction de dimensionnalité qui transforme les données en un espace de dimension inférieure.

Méthodes d'échantillonnage : La réduction de la taille de l'ensemble de données par la sélection d'échantillons représentatifs est utile pour traiter de grands ensembles de données.

Étapes du prétraitement des données

- Étape 6 : Séparation des données en ensembles d'entraînement et de test

Avant de commencer l'entraînement d'un modèle, il est important de séparer les données en un ensemble d'entraînement (pour apprendre le modèle) et un ensemble de test (pour évaluer la performance du modèle).

- Étape 7 : Équilibrage des classes

Lorsque l'on travaille avec des ensembles de données déséquilibrés (par exemple, beaucoup plus d'exemples d'une classe que de l'autre), il est important de traiter cet équilibre.

- Sous-échantillonnage de la classe majoritaire.
- Sur-échantillonnage de la classe minoritaire (par exemple, en utilisant la méthode SMOTE).

Conclusion

- Le prétraitement des données est une étape cruciale dans tout projet de machine learning.
- Il consiste à préparer les données pour l'analyse en les nettoyant, en les transformant et en les organisant.
- Les techniques couramment utilisées dans le prétraitement des données comprennent le nettoyage des données, la mise à l'échelle des caractéristiques, la discrétisation des données et l'ingénierie des caractéristiques.
- Le prétraitement des données peut améliorer la précision des modèles d'apprentissage automatique en supprimant le bruit et les informations non pertinentes des données.
- La qualité des résultats des modèles d'apprentissage automatique dépend fortement de la qualité des données prétraitées.
- En résumé, le prétraitement des données est une étape essentielle qui ne doit être négligée dans aucun projet de machine learning.