

TP5 : Apache SPARK

Objectifs

- Installer SPARK en standalone
- Travailler en local avec un fichier CSV (pas de Hadoop requis)
- Comprendre la logique de base d'un traitement Spark.
- Manipuler des DataFrames.
- Effectuer des filtres, agrégations et tris.

NB : Ce TP peut être réalisé en Spark avec Python (PySpark), Scala ou Java selon vos préférences si vous voulez taper du code, sinon, vous pouvez utiliser une interface graphique et réaliser les opérations sans coder en installant Apache Zeppelin pour avoir une interface web plus conviviale.

Pour commencer, il faut installer SARK en standalone sans installation préalable de Hadoop.

Prérequis d'installation

- Java JDK (8 ou 11 recommandé)
- Python (pour utiliser PySpark)
- Apache Spark (standalone)
- WinUtils.exe (petit utilitaire requis par Spark sur Windows)
- Apache Zeppelin (*facultatif pour l'interface graphique*)

Procédure d'installation

- Installer Java et ajouter la variable d'environnement.
- Installer Python (cocher la case Add Python to PATH).
- Installer SPARK (aller à la page : [Spark Download Page](#), choisir, la version 3.5.x , avec Package : Pre-built for Apache Hadoop 3.3 and later, extraire le ZIP dans un dossier (ex: C:\spark).
- Télécharger le fichier winutils.exe (utile pour spark sous windows) depuis: <https://github.com/steveloughran/winutils>, choisir la version Hadoop 3.3.0 pour Spark 3.5.x).
- Place-le fichier winutils.exe dans un dossier comme C:\hadoop\bin\winutils.exe.
- Créer une variable d'environnement : HADOOP_HOME = C:\hadoop.
- Ajouter aussi %HADOOP_HOME%\bin dans le PATH.
- Configurer les variables d'environnement :

Nom	Valeur
SPARK_HOME	C:\spark
HADOOP_HOME	C:\hadoop
JAVA_HOME	C:\Program Files\Java\jdk-11
PATH	%SPARK_HOME%\bin (et %HADOOP_HOME%\bin)

Avant de commencer, il faut d'abord vérifier si votre installation a réussi, pour cela :

Ouvrir cmd ou PowerShell et taper *spark-shell*

Si tout est bien installé, on verra l'invite Spark Scala REPL. On peut aussi lancer PySpark avec : *pyspark*

Contexte du TP : Vous travaillez pour une collectivité qui souhaite analyser la consommation énergétique des foyers de plusieurs villes. Les données sont enregistrées quotidiennement dans un fichier conso_energie.csv comme suit :

client_id	date	ville	consommation_kWh
101	2025-01-01	Paris	5.3
102	2025-01-01	Lyon	0
103	2025-01-01	Marseille	8.2
101	2025-01-02	Paris	4.7
102	2025-01-02	Lyon	2.4

Travail demandé :

1. Charger le fichier conso_energie.csv dans un DataFrame.
2. Afficher les 5 premières lignes.
3. Afficher le schéma du DataFrame (types des colonnes).
4. Supprimer les lignes avec une consommation nulle ou égale à 0.
5. Supprimer les lignes avec des champs manquants (nulls).
6. Calculer la consommation totale par client.
7. Calculer la consommation moyenne par ville.
8. Identifier la ville avec la plus forte consommation moyenne.
9. Trier les clients par consommation totale décroissante.
10. Afficher les 10 clients les plus consommateurs.
11. Extraire le jour de la semaine à partir de la date.
12. Calculer la consommation moyenne par jour de la semaine.

Questions

1. Quelles transformations avez-vous utilisées pour nettoyer les données ?
2. Quelle est la ville la plus « énergivore » ?
3. Le top 3 des clients les plus consommateurs est-il concentré dans une même ville ?
4. Quel est le jour de la semaine où consommation est la plus forte ?